

# Saulės elektrinių pagaminamos elektros kiekio prognozavimo literatūros apžvalga

Matas Amšiejus ir Antanas Užpelkis

Darbo vadovė: Doc. Dr. Jurgita Markevičiūtė

# Saulės jėgainių pagaminamos elektros energijos kiekio prognozavimas pagal orus ir oro taršą naudojant mašininio mokymosi metodus

- Autoriai: Tserenpurev Chuluunsaikhan, Aziz Nasridinov, Woo Seok Choi, Da Bin Choi, Sang Hyun Choi, Young Myoung Kim;
- „Journal of Korea Multimedia Society“, 24 tomas, 2 numeris, 2021 vasaris (222-232 pusl.);
- „Predicting the Power Output of Solar Panels based on Weather and Air Pollution Features using Machine Learnin“

# Naudoti metodai

Tyrime buvo naudojami keli skirtingi metodai:

- tiesinė regresija;
- kNN (artimiausio k kaimyno metodas);
- SVR (atraminių vektorių regresija);
- MLP (daugiasluoksnis perceptronas);
- RF (atsitiktinių miškų metodas);
- GB (*padidinto gradiento* metodas angl. „Gradient Boosting“)

# Kintamieji

Priklausomas kintamasis – pagamintos energijos kiekis.

Nepriklausomi kintamieji:

- Duomenys iš kolektoriaus: galios faktorius (pagamintos ir sunaudotos energijos santykis), nuokrypio kampas (kolektoriaus nukrypimas nuo horizontalaus paviršiaus), spinduliuotė patenkanti ant paviršiaus, kolektoriaus temperatūra.
- Meteorologiniai duomenys: drėgmė, giedrumas, spinduliuotė patenkanti ant žemės, debesuotumas, temperatūra.
- Užterštumo duomenys: ozono, sieros rūgšties dujų, azoto dioksido, smalkių, smulkių dulkių, smulkių kietųjų dalelių kiekis.
- Išvestiniai duomenys: mėnuo, valanda.

# Išvados

Tyrime išanalizuoti skirtingi MM metodai ir skirtingos kintamųjų kombinacijos:

- kolektoriaus kintamieji;
- meteorologiniai kintamieji;
- oro užterštumo kintamieji;
- labiausiai koreliuoti kintamieji (galios faktorius, nuokrypio kampas, spinduliuotė patenkanti ant paviršiaus, kolektoriaus temperatūra, giedrumas, spinduliuotė patenkanti ant žemės);
- visi kintamieji.

Visi metodai yra tinkami naudojimui (apie 95% tikslumas), tačiau geriausius rezultatus turėjo RF metodas naudojant visus kintamuosius ( $R^2$  98.25%, RMSE 0.89, MAE 0.28). Taip pat pastebėta, kad oro taršos įtaka yra mažiausia iš visų, o modeliai su šiomis kovariantėmis turi palyginus mažus tikslumus.

# Duomenų analizė regresijos ir neuroninių tinklų modeliams skirtiems prognozuoti saulės energijos gamybos prognozei

- 2016 metų 7-oji tarptautinė intelektinių sistemų, modeliavimo ir simuliacijų (ISMS) konferencija.
- Autoriai: Tushar Verma, A. P. S. Tiwana, C. C. Reddy, Vikas Arora and P. Devanand
- „Data Analysis to Generate Models Based on Neural Network and Regression for Solar Power Generation Forecasting“

# Metodai ir kintamieji

Metodai:

- Tiesinė regresija;
- Logaritminė regresija;
- Polinominė regresija;
- Dirbtiniai neuroniniai tinklai (DNT) (Levenberg-Marquardt algoritmas (LMA)).

Priklausomas kintamasis – pagaminamos energijos kiekis.

Nepriklausomi kintamieji:

- Duomenys iš kolektoriaus: kolektoriaus temperatūra;
- Meteorologiniai duomenys: debesuotumas, vėjo greitis, drėgmė, krituliai;
- Geografiniai duomenys: saulės pakilimo ir azimuto kampai.

# Išvados

- Naudojant tiesinę regresiją vėjo greitis ir drėgmė buvo nereikšmingi.
- Naudojant logaritminę regresiją debesuotumas buvo nereikšmingas.
- Polinominėje regresijoje visi pirmo ir trečio laipsnio kintamieji bei ketvirto laipsnio krituliai buvo nereikšmingi.

Logaritminė regresija buvo mažiausiai tiksli ( $R^2$  47.4 % ir 15 % paklaida), tiesinė ir polinominė regresijos buvo panašaus tikslumo ( $R^2$  74.4 % ir 75.1 %; paklaidos 6 % ir 6.1 %), o DNT buvo tiksliausi ( $R^2$  92 %, 3 % paklaida).

Papildomas faktas: paminėta saulės elektrinių degradacija, kuri nulemia mažėjantį saulės jėgainių pagaminamos energijos kiekį su kiekvienais metais.



# Didžiųjų duomenų analizės naudojimas regresijoje prognozuojant pagaminamą saulės energiją Korėjos saulės elektrinėse naudojant meteorologinius duomenis

- Autoriai: Young Seo Kim, Han Young Joo , Jae Wook Kim, So Yun Jeong and Joo Hyun Moon.
- Iš specialaus leidinio „Dirbtinis intelektas energijos sistemų programoms“. 2021 sausis.
- „Use of a Big Data Analysis in Regression of Solar Power Generation on Meteorological Variables for a Korean Solar Power Plant “

# Naudoti modeliai ir kintamieji

Tiesinė regresija (bendras modelis ir kiekvieno mėnesio atskiras modelis).

Priklausomas kintamasis - pagaminamos energijos kiekis.

Nepriklausomi kintamieji: spinduliuotė piko metu, spinduliuotė šviesiuoju paros metu, dienos ilgumas, vidutinė santykinė drėgmė, minimali santykinė drėgmė, garavimo kiekis.

# Išvados

- Visi kintamieji buvo reikšmingi, tačiau spinduliuotės kiekis piko metu buvo pašalintas iš modelio, nes buvo stipriai multikolinearus. Bendras modelis turėjo  $R^2 = 0.7735$ , o  $RMSE = 69.06$ .
- Iš 12 atskirų modelių kiekvienam mėnesiui tiksliausias buvo sausį ( $R^2 = 0.8985$ ,  $RMSE = 40.66$ ). Prasčiausias tikslumas buvo gruodžio mėnesį ( $R^2 = 0.7228$ ,  $RMSE = 68.39$ ).
- Darbe buvo teigiama, kad svarbiausios kovariantės buvo spinduliuotė šviesiuoju paros metu bei dienos ilgumas.
- Iš atskirų mėnesių modelių buvo nustatyta, kad kovariančių svarba kito priklausomai nuo mėnesio.

# Horizontalių saulės kolektorių pagaminamos energijos kiekio modeliavimas naudojant tiesinę regresiją ir atsitiktinius miškus

- Autorius: Christil K. Pasion.
- JAV karinių oro pajėgų technologijų instituto tezių ir disertacijų rinkinys, 2019 kovo 21.
- „Modeling Power Output of Horizontal Solar Panels Using Multivariate Linear Regression and Random Forest Machine Learning“

# Naudoti modeliai ir kintamieji

Modeliai:

- Tiesinė regresija;
- Atsitiktiniai miškai (RF);

Priklausomas kintamasis - pagaminamos energijos kiekis.

Nepriklausomi kintamieji:

- Meteorologiniai duomenys: drėgmė, aplinkos temperatūra, vėjo greitis, matomumas, debesuotumas, slėgis.
- Geografiniai duomenys: platuma, aukštuma.
- Laikas: mėnuo, valanda.

# Išvados

- Tiesinės regresijos modelio  $R^2 = 0.562$ , atsitiktinių sprendimų miškų  $R^2 = 0.658$ .
- RF modelyje svarbiausios kovariantės buvo mėnuo ir debesuotumas, mažiausią įtaką turėjo matomumas ir vėjo greitis.
- Tiesinės regresijos modelio nebuvo galima tiesiogiai interpretuoti, nes jis netenkino visų reikalingų sąlygų, kintamieji buvo smarkiai modifikuoti.
- Tiesinės regresijos modelis atmetė matomumo kovariantę kaip nereikšmingą, temperatūra, vėjo greitis, debesuotumas turėjo teigiamą saryšį, o platuma, drėgmė ir aukštis - neigiamą.

# Nuorodos

- Pirmas šaltinis: [Predicting the Power Output of Solar Panels based on Weather and Air Pollution Features using Machine Learning -Journal of Korea Multimedia Society | Korea Science](#)
- Antras šaltinis: [Data Analysis to Generate Models Based on Neural Network and Regression for Solar Power Generation Forecasting | IEEE Conference Publication | IEEE Xplore](#)
- Trečias šaltinis: [Applied Sciences | Free Full-Text | Use of a Big Data Analysis in Regression of Solar Power Generation on Meteorological Variables for a Korean Solar Power Plant \(mdpi.com\)](#)
- Ketvirtas šaltinis: ["Modeling Power Output of Horizontal Solar Panels Using Multivariate Li" by Christil K. Pasion \(afit.edu\)](#)